


Neuronové sítě a hluboké učení


Label: 0, Predicted: 0
with 0.383 confidence



Label: 3, Predicted: 3
with 0.277 confidence



Label: 6, Predicted: 6
with 0.226 confidence




Neuronové sítě a hluboké učení

- Michael N. Nielsen, “**Neural Networks and Deep Learning**”, Determination Press, 2015
- <http://neuralnetworksanddeeplearning.com/>
- [3blue1brown série videí na YouTube](#)
- pevné základy, ne přehled technik
- příklady v **Pythonu**, bez frameworků

Rozpoznání ručně psaných číslic


- Standardními technikami hrozně složité
- Zkusíme jiný přístup: udělat program, který se na základě dat “naučí”, jak která číslice vypadá
- Vyjdeme z toho, že existuje nějaká (matematická) funkce, která problém řeší \Rightarrow budeme ji chtít najít
- **Fitování funkce**

Rozpoznání ručně psaných číslic



Model neuronu - perceptron

- n binárních vstupů, jeden binární výstup
- váhy, prahová hodnota



Model neuronu - perceptron

$$\text{output} = \begin{cases} 0 & \text{if } \sum_j w_j x_j \leq \text{threshold} \\ 1 & \text{if } \sum_j w_j x_j > \text{threshold} \end{cases}$$

Model neuronu - perceptron

- váhy značí důležitost vstupní proměnné
- prahová hodnota jak “těžké” je aktivovat perceptron

$$\text{output} = \begin{cases} 0 & \text{if } \sum_j w_j x_j \leq \text{threshold} \\ 1 & \text{if } \sum_j w_j x_j > \text{threshold} \end{cases}$$

Model neuronu - perceptron

- model rozhodování
- příklad: výběr vysoké školy
 1. dobré uplatnění
 2. vysoká obtížnost
 3. osobní zájem

Model neuronu - perceptron

- model rozhodování
- příklad: výběr vysoké školy
 1. dobré uplatnění
 2. vysoká obtížnost
 3. osobní zájem
- **každý může přiřadit vstupům jinou váhu a má jinou prahovou hodnotu**

Model neuronu - perceptron

- vhodnější notace: zavedeme tzv. ***bias***


$$b := -threshold$$

- skalární součin: $\sum_{i=1}^n w_i x_i + b = w^T x + b$

$$\text{output} = \begin{cases} 1 & \dots \text{pokud } w^T \cdot x + b_i > 0, \\ 0 & \dots \text{pokud } w^T \cdot x + b_i \leq 0 \end{cases}$$


Sít' perceptronů

- vrstvy vzájemně “propojených” perceptronů
- komplexní rozhodovací model
- druhá vrstva je abstraktnější




Sít' perceptronů

- model jakékoliv logické funkce
- NAND, univerzální logický člen




Sít' perceptronů

- model jakékoliv logické funkce
- NAND, univerzální logický člen



Model neuronu - spojitý neuron

- sigmoid neuron
- abychom mohli nastavit váhy a biasy, chceme spojitost



Model neuronu - spojitý neuron

- změna váhy/biasu perceptronu může úplně změnit výstup sítě, nebo naopak nezpůsobit nic
- dovolíme $\text{output} = y \in (0, 1)$
- aktivační funkce ***sigmoid***

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(\sum_i^n w_i x_i + b)}}$$


Model neuronu - spojitý neuron

- pokud z velké záporné, output se blíží k 0
- pokud z velké kladné, output se blíží k 1
- v limitách stejné, jako perceptrony


$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(\sum_i^n w_i x_i + b)}}$$

Model neuronu - spojitý neuron

Sigmoid function



Step function



Model neuronu - spojitý neuron

- zafixujeme vstup, neuron je funkce, ve které jsou váhy a bias proměnné
- chceme, aby změna v proměnné byla lineárně proporční změně výstupu - **spojitost**

$$\Delta \text{output} \approx \sum_j \frac{\partial \text{output}}{\partial w_j} \Delta w_j + \frac{\partial \text{output}}{\partial b} \Delta b$$

Cvičení 1

- Ukažte, že vynásobíme-li všechny váhy a biasy v síti perceptronů kladnou konstantou, chování sítě se nezmění

Cvičení 1

- Ukažte, že vynásobíme-li všechny váhy a biasy v síti perceptronů kladnou konstantou, chování sítě se nezmění
- output jednoho perceptronu:

$$y = \begin{cases} 0 \dots \text{pokud } w^T x + b \leq 0, \\ 1 \dots \text{pokud } w^T x + b > 0. \end{cases}$$

- rozepíšeme skalární součin
a vynásobíme váhy a bias konstantou c :

Cvičení 1

- Ukažte, že vynásobíme-li všechny váhy a biasy v síti perceptronů kladnou konstantou, chování sítě se nezmění
- output jednoho perceptronu:

$$y = \begin{cases} 0 \dots \text{pokud } w^T x + b \leq 0, \\ 1 \dots \text{pokud } w^T x + b > 0. \end{cases}$$

- rozepíšeme skalární součin
a vynásobíme váhy a bias konstantou c :

$$\sum_{i=1}^n c w_i x_i + c b = c \sum_{i=1}^n w_i x_i + c b = c w x + c b = c(w x + b)$$

Cvičení 1

$$\sum_{i=1}^n cw_ix_i + cb = c \sum_{i=1}^n w_ix_i + cb = cw^Tx + cb = c(w^Tx + b)$$

Cvičení 1

$$\sum_{i=1}^n cw_ix_i + cb = c \sum_{i=1}^n w_ix_i + cb = cw^Tx + cb = c(w^Tx + b)$$

- dosadíme do definice perceptronu, můžeme vydělit kladnou konstantou beze změny nerovnosti

Cvičení 1

$$\sum_{i=1}^n cw_ix_i + cb = c \sum_{i=1}^n w_ix_i + cb = cw^Tx + cb = c(w^Tx + b)$$

- dosadíme do definice perceptronu, můžeme vydělit kladnou konstantou beze změny nerovnosti

$$y = \begin{cases} 0 \dots \text{pokud } c(w^Tx + b) \leq 0 \equiv w^Tx + b \leq 0, \\ 1 \dots \text{pokud } c(w^Tx + b) > 0 \equiv w^Tx + b > 0. \end{cases}$$

Cvičení 1

$$\sum_{i=1}^n cw_ix_i + cb = c \sum_{i=1}^n w_ix_i + cb = cw^Tx + cb = c(w^Tx + b)$$

- dosadíme do definice perceptronu, můžeme vydělit kladnou konstantou beze změny nerovnosti

$$y = \begin{cases} 0 \dots \text{pokud } c(w^Tx + b) \leq 0 \equiv w^Tx + b \leq 0, \\ 1 \dots \text{pokud } c(w^Tx + b) > 0 \equiv w^Tx + b > 0. \end{cases}$$

- to platí pro libovolný perceptron, tedy i pro celou síť

Cvičení 2

- Mějme fixní vstup do sítě perceptronů tak, že: $w^T x + b \neq 0$
Zaměňte všechny perceptrony za spojité neurony a vynásobte kladnou konstantou c . Ukažte, že pro $c \rightarrow +\infty$ se síť chová stejně jako původní síť perceptronů. Co se stane, pokud pro nějaký neuron neplatí $w^T x + b \neq 0$?

Cvičení 2

- Mějme fixní vstup do sítě perceptronů tak, že: $w^T x + b \neq 0$
Zaměňte všechny perceptrony za spojité neurony a vynásobte kladnou konstantou c . Ukažte, že pro $c \rightarrow +\infty$ se síť chová stejně jako původní síť perceptronů. Co se stane, pokud pro nějaký neuron neplatí $w^T x + b \neq 0$?
- opět prozkoumáme chování jednoho neuronu

Cvičení 2

$$\begin{aligned} y = \sigma(w^T x + b) &= \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1} \\ &= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b \end{aligned}$$

Cvičení 2

$$y = \sigma(w^T x + b) = \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1}$$

$$= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b$$

- vynásobíme konstantou $c > 0$ a dostaneme $1 - \frac{1}{e^{ct} + 1}$.

Cvičení 2

$$y = \sigma(w^T x + b) = \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1}$$

$$= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b$$

- vynásobíme konstantou $c > 0$ a dostaneme $1 - \frac{1}{e^{ct} + 1}$.
- Rozlišíme tři případy:

Cvičení 2

$$y = \sigma(w^T x + b) = \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1}$$

$$= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b$$

- vynásobíme konstantou $c > 0$ a dostaneme $1 - \frac{1}{e^{ct} + 1}$.
- Rozlišíme tři případy:

$t > 0$:

Cvičení 2

$$y = \sigma(w^T x + b) = \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1}$$

$$= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b$$

- vynásobíme konstantou $c > 0$ a dostaneme $1 - \frac{1}{e^{ct} + 1}$.
- Rozlišíme tři případy:

$$t > 0 : e^{ct} \xrightarrow{c \rightarrow +\infty} +\infty \Rightarrow \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 0 \Rightarrow 1 - \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 1.$$

Cvičení 2

$$y = \sigma(w^T x + b) = \frac{1}{1 + \exp(-(w^T x + b))} = \frac{1}{1 + \frac{1}{e^{w^T x + b}}} = \frac{e^{w^T x + b}}{e^{w^T x + b} + 1} = \frac{e^t}{e^t + 1}$$
$$= \frac{e^t + 1 - 1}{e^t + 1} = 1 - \frac{1}{e^t + 1}, \text{ přičemž } t = wx + b$$

- vynásobíme konstantou $c > 0$ a dostaneme $1 - \frac{1}{e^{ct} + 1}$.
- Rozlišíme tři případy:

$$t > 0 : e^{ct} \xrightarrow{c \rightarrow +\infty} +\infty \Rightarrow \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 0 \Rightarrow 1 - \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 1.$$

- zároveň víme, že vynásobením vah a biasu perceptronu nezměníme jeho výstup, sítě se tedy chovají stejně

Cvičení 2

- výstup neuronu: $y = 1 - \frac{1}{e^t + 1}$

$t < 0$:

Cvičení 2

- výstup neuronu: $y = 1 - \frac{1}{e^t + 1}$

$$t < 0 : e^{ct} \xrightarrow{c \rightarrow +\infty} 0 \Rightarrow \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 1 \Rightarrow 1 - \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 0$$

Cvičení 2

- výstup neuronu: $y = 1 - \frac{1}{e^t + 1}$

$$t < 0 : e^{ct} \xrightarrow{c \rightarrow +\infty} 0 \Rightarrow \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 1 \Rightarrow 1 - \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 0$$

$t = 0$: • bude existovat neuron, pro který:

Cvičení 2

- výstup neuronu: $y = 1 - \frac{1}{e^t + 1}$

$$t < 0 : e^{ct} \xrightarrow{c \rightarrow +\infty} 0 \Rightarrow \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 1 \Rightarrow 1 - \frac{1}{e^{ct} + 1} \xrightarrow{c \rightarrow +\infty} 0$$

$t = 0$: • bude existovat neuron, pro který:

$$1 - \frac{1}{e^{ct} + 1} = 1 - \frac{1}{e^0 + 1} = 1 - \frac{1}{1 + 1} = \frac{1}{2} \xrightarrow{c \rightarrow +\infty} \frac{1}{2}$$

Poznámka

- Vstupní vrstvu zakreslujeme jako vrstvu neuronů, byť formálně není, vrstvy mezi vstupem a výstupem nazveme ***skrytými***
- Bavíme se o tzv. ***feedforward*** sítích - tj. zakazujeme smyčky
- Často se těmto sítím říká Multi Layer Perceptron (MLP)

Poznámka

