



Jak se neuronové sítě učí




Model neuronu - spojitý neuron

- n vstupů, 1 výstup
- $n+1$ parametrů
- **Jak určit počet parametrů MLP?**



Model neuronu - spojitý neuron


- n vstupů, 1 výstup
- $n+1$ parametrů
- **Jak určit počet parametrů MLP?**



$$\sum_{i=2}^k N_i \cdot (N_{i-1} + 1)$$


Model neuronu - spojitý neuron

- n vstupů, 1 výstup
- $n+1$ parametrů




- **Jak určit počet parametrů MLP?**

$$\sum_{i=2}^k N_i \cdot (N_{i-1} + 1)$$




Model neuronu - spojitý neuron

- n vstupů, 1 výstup
- $n+1$ parametrů
- **Jak určit počet parametrů MLP?**




$$\sum_{i=2}^k N_i \cdot (N_{i-1} + 1)$$



$$4 \cdot (3 + 1) + 1 \cdot (4 + 1) = 21$$

Rozpoznávání ručně psaných číslic

- MNIST dataset - 60 000 obrázků ručně psaných číslic od 250 lidí pro trénink, 10 000 obrázků pro test psaných jinými 250 lidmi => chceme robustní systém, co rozpozná ručně psané číslice!
- vstup budeme značit jako \mathbf{x} , výstup \mathbf{y}



Rozpoznávání ručně psaných číslic

- Vstupní obrázek má $28 \times 28 = 784$ pixelů => vstupní vrstva 784 neuronů
- **Kolik výstupní vrstva?**

Rozpoznávání ručně psaných číslic

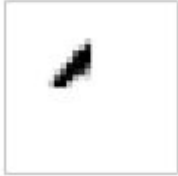

- Vstupní obrázek má $28 \times 28 = 784$ pixelů \Rightarrow vstupní vrstva 784 neuronů
- **Kolik výstupní vrstva?**
 - a. 10 neuronů - 1 za každou číslici**
 - b. 4 neurony - v binárním vyjádření
 - c. 1 neuron - přímá hodnota

10 neuronů ve výstupní vrstvě

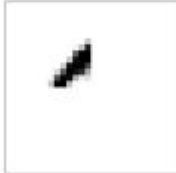

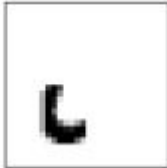


- Divoká fabulace: Představte si, že první neuron v předposlední vrstvě detekuje (pomocí váženého součtu předchozích neuronů) podobný tvar



10 neuronů ve výstupní vrstvě

- Divoká fabulace: Představte si, že první neuron v předposlední vrstvě detekuje (pomocí váženého součtu předchozích neuronů) podobný tvar 
- Další neurony tyto tvary 

10 neuronů ve výstupní vrstvě

- Divoká fabulace: Představte si, že první neuron v předposlední vrstvě detekuje (pomocí váženého součtu předchozích neuronů) podobný tvar 
- Další neurony tyto tvary 
- Váženým součtem přes ně bychom zjistili, že tento tvar je 0 


10 neuronů ve výstupní vrstvě

Jak udělat tenhle intuitivní přechod pro binární reprezentaci?

Cvičení 3

- Existuje způsob, jak zakódovat output sítě s deseti výstupními neurony do binární soustavy přidáním další vrstvy obsahující čtyři neurony. Určete jejich váhy a biasy. Předpokládejte, že správná číslice má aktivaci alespoň 0.99.


Cvičení 3



Cvičení 3

- Reprezentace čísel 0-9 v binární soustavě:

0 - 0000,	5 - 0101,
1 - 0001,	6 - 0110,
2 - 0010,	7 - 0111,
3 - 0011,	8 - 1000,
4 - 0100,	9 - 1001.



Cvičení 3

0 - 0000,	5 - 0101,
1 - 0001,	6 - 0110,
2 - 0010,	7 - 0111,
3 - 0011,	8 - 1000,
4 - 0100,	9 - 1001.

- 4 výstupní neurony - chceme zvolit váhy tak, aby např. první neuron aktivovala číslce 1, 3, 5, 7, 9 =>

Cvičení 3

0 - 0000, 5 - 0101,
1 - 0001, 6 - 0110,
2 - 0010, 7 - 0111,
3 - 0011, 8 - 1000,
4 - 0100, 9 - 1001.

- 4 výstupní neurony - chceme zvolit váhy tak, aby např. první neuron aktivovala čísla 1, 3, 5, 7, 9 =>

spojení mezi nimi přiřadíme váhu 1, ostatním 0,
bias zvolíme např. 0.99

Cvičení 3

0 - 0000, 5 - 0101,
1 - 0001, 6 - 0110,
2 - 0010, 7 - 0111,
3 - 0011, 8 - 1000,
4 - 0100, 9 - 1001.

- 4 výstupní neurony - chceme zvolit váhy tak, aby např. první neuron aktivovala čísla 1, 3, 5, 7, 9 =>

spojení mezi nimi přiřadíme váhu 1, ostatním 0, bias zvolíme např. 0.99

- druhý neuron aktivujeme pomocí 2, 3, 6, 7 => váhy těchto spojení zvolíme 1, ostatní 0 a bias 0.99

Učení NN

- vstup \mathbf{x} , výstup $\mathbf{y} = \mathbf{y}(\mathbf{x})$

Učení NN

- vstup \mathbf{x} , výstup $\mathbf{y} = \mathbf{y}(\mathbf{x})$
- výstup z naší NN je deset čísel (neuronů), proto i naše \mathbf{y} musí být vektor o deseti číslech se samými nulami a jednou jedničkou

Učení NN

- vstup \mathbf{x} , výstup $\mathbf{y} = \mathbf{y}(\mathbf{x})$
- výstup z naší NN je deset čísel (neuronů), proto i naše \mathbf{y} musí být vektor o deseti číslech se samými nulami a jednou jedničkou
- hledáme algoritmus, který nám umožní najít váhy a biasy tak, aby síť aproximovala $\mathbf{y}(\mathbf{x})$ pro všechna tréninková data v datasetu

Učení NN

- vstup \mathbf{x} , výstup $\mathbf{y} = \mathbf{y}(\mathbf{x})$
- výstup z naší NN je deset čísel (neuronů), proto i naše \mathbf{y} musí být vektor o deseti číslech se samými nulami a jednou jedničkou
- hledáme algoritmus, který nám umožní najít váhy a biasy tak, aby síť aproximovala $\mathbf{y}(\mathbf{x})$ pro všechna tréninková data v datasetu \Rightarrow **účelová funkce**

Učení NN - účelové funkce

- účelová funkce (cost, loss or objective function)

$$C(w, b) \equiv \frac{1}{2n} \sum_x \|y(x) - a\|^2$$

Učení NN - účelové funkce

- účelová funkce (cost, loss or objective function)

$$C(w, b) \equiv \frac{1}{2n} \sum_x \|y(x) - a\|^2$$

- **w , b** je vektor všech vah, respektive biasů, **n** počet tréninkových dat, **a** výstup sítě, **$a = a(w, b, x)$**
- quadratic cost function, mean squared error (MSE)

Učení NN - účelové funkce

- platí: $C(w, b) \geq 0$

Učení NN - účelové funkce

- platí: $C(w, b) \geq 0$
 $C(w, b) \approx 0 \iff y(x) \approx a(w, b, x)$

Učení NN - účelové funkce

- platí: $C(w, b) \geq 0$
 $C(w, b) \approx 0 \iff y(x) \approx a(w, b, x)$

$$C(w, b) \rightarrow \min$$

Učení NN - účelové funkce

- proč účelová funkce a ne přímo počet správně klasifikovaných číslí?

Učení NN - účelové funkce

- proč účelová funkce a ne přímo počet správně klasifikovaných číslí? **Potřebujeme spojitost vůči vahám a biasům**

Učení NN - účelové funkce

- proč účelová funkce a ne přímo počet správně klasifikovaných číslí? **Potřebujeme spojitost vůči vahám a biasům**
- proč zrovna tahle účelová funkce?


Učení NN - účelové funkce

- proč účelová funkce a ne přímo počet správně klasifikovaných číslí? **Potřebujeme spojitost vůči vahám a biasům**
- proč zrovna tahle účelová funkce? **Možností je víc a jiná účelová funkce povede k jinému učení (a následně výkonu). Prozatím neřešíme**

Učení NN - gradient descent


Učení NN - gradient descent

- Začneme lehčí úlohou: minimalizovat funkci dvou proměnných $f(\mathbf{x}, \mathbf{y})$



Učení NN - gradient descent

- Začneme lehčí úlohou: minimalizovat funkci dvou proměnných $f(x,y)$
- **Jak tuto úlohu vyřešit?**



Učení NN - gradient descent

- analyticky to může být těžké, zvlášť budeme-li chtít postup zobecnit pro libovolný počet proměnných

Učení NN - gradient descent

- analyticky to může být těžké, zvlášť budeme-li chtít postup zobecnit pro libovolný počet proměnných
- heuristika: začneme z libovolného bodu a budeme se vždy posouvat tak, aby se hodnota $f(\mathbf{x}, \mathbf{y})$ snižovala (kutálející míč)

Učení NN - gradient descent

- analyticky to může být těžké, zvlášť budeme-li chtít postup zobecnit pro libovolný počet proměnných
- heuristika: začneme z libovolného bodu a budeme se vždy posouvat tak, aby se hodnota $f(\mathbf{x}, \mathbf{y})$ snižovala (kutálející míč)
- Takhle nalezneme alespoň lokální minimum

Učení NN - gradient descent

- Chceme zvolit Δx a Δy tak, aby Δf bylo negativní

Učení NN - gradient descent

- Chceme zvolit Δx a Δy tak, aby Δf bylo negativní
- Díky spojitosti:

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

Učení NN - gradient descent

- Využijeme gradient (směr nejprudšího růstu “steepest ascent”)

Učení NN - gradient descent

- Využijeme gradient (směr nejprudšího růstu “steepest ascent”)

$$\begin{aligned}\overrightarrow{\nabla f} &= \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} \\ \overrightarrow{\Delta v} &:= \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}\end{aligned}\Rightarrow$$

Učení NN - gradient descent

- Využijeme gradient (směr nejprudšího růstu “steepest ascent”)

$$\begin{aligned} \overrightarrow{\nabla f} &= \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} \\ \overrightarrow{\Delta v} &:= \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} \end{aligned} \quad \Rightarrow \quad \Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v}.$$

Učení NN - gradient descent

- Chceme najít takové $\vec{\Delta v}$, aby byla $\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v}$.
negativní bez závislosti na znaménku gradientu

Učení NN - gradient descent

- Chceme najít takové $\vec{\Delta v}$, aby byla $\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v}$.
negativní bez závislosti na znaménku gradientu
- volba $\vec{\Delta v} := -\xi \vec{\nabla f}$, tzv. *learning rate*

Učení NN - gradient descent

- Chceme najít takové $\vec{\Delta v}$, aby byla $\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v}$.
negativní bez závislosti na znaménku gradientu
- volba $\vec{\Delta v} := -\xi \vec{\nabla f}$, tzv. *learning rate*

$$\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v} = -\vec{\nabla f}^T \cdot \xi \vec{\nabla f} = -\xi \|\vec{\nabla f}\|^2$$

Učení NN - gradient descent

- Chceme najít takové $\vec{\Delta v}$, aby byla $\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v}$.
negativní bez závislosti na znaménku gradientu
- volba $\vec{\Delta v} := -\xi \vec{\nabla f}$, tzv. *learning rate*

$$\Delta f \approx \vec{\nabla f}^T \cdot \vec{\Delta v} = -\vec{\nabla f}^T \cdot \xi \vec{\nabla f} = -\xi \|\vec{\nabla f}\|^2$$

- Pravidlo pro změnu **x** a **y** $\vec{v} \rightarrow \tilde{\vec{v}} = \vec{v} - \xi \vec{\nabla f}$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

$$\overrightarrow{\nabla f} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\overrightarrow{\Delta v} := \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v}.$$

$$\overrightarrow{\nabla f} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\overrightarrow{\Delta v} := \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v}.$$

$$\overrightarrow{\Delta v}^- := -\xi \overrightarrow{\nabla f}$$

$$\overrightarrow{\nabla f} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\overrightarrow{\Delta v} := \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v}.$$

$$\overrightarrow{\Delta v} := -\xi \overrightarrow{\nabla f}$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v} = -\overrightarrow{\nabla f}^T \cdot \xi \overrightarrow{\nabla f} = -\xi \left\| \overrightarrow{\nabla f} \right\|^2$$

$$\overrightarrow{\nabla f} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\overrightarrow{\Delta v} := \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Shrnutí

$$\Delta f \approx \frac{\partial f}{\partial x} \Delta x + \frac{\partial f}{\partial y} \Delta y$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v}.$$

$$\overrightarrow{\Delta v}^- := -\xi \overrightarrow{\nabla f}$$

$$\Delta f \approx \overrightarrow{\nabla f}^T \cdot \overrightarrow{\Delta v} = -\overrightarrow{\nabla f}^T \cdot \xi \overrightarrow{\nabla f} = -\xi \left\| \overrightarrow{\nabla f} \right\|^2$$

$$\vec{v} \rightarrow \vec{\tilde{v}} = \vec{v} - \xi \overrightarrow{\nabla f}$$

$$\overrightarrow{\nabla f} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\overrightarrow{\Delta v} := \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix}$$

Učení NN - gradient descent

- Zobecníme algoritmus pro funkci n parametrů

$$\overrightarrow{\nabla f} = \left(\frac{\partial f}{\partial v_1}, \dots, \frac{\partial f}{\partial v_n} \right)^T$$

Učení NN - gradient descent

- Zobecníme algoritmus pro funkci n parametrů

$$\overrightarrow{\nabla f} = \left(\frac{\partial f}{\partial v_1}, \dots, \frac{\partial f}{\partial v_n} \right)^T$$

- Algoritmus můžeme použít na naší účelovou

funkci $C(w, b) \equiv \frac{1}{2n} \sum_x \|y(x) - a\|^2$

Učení NN - gradient descent

- Zobecníme algoritmus pro funkci n parametrů

$$\overrightarrow{\nabla f} = \left(\frac{\partial f}{\partial v_1}, \dots, \frac{\partial f}{\partial v_n} \right)^T$$

- Algoritmus můžeme použít na naší účelovou

funkci $C(w, b) \equiv \frac{1}{2n} \sum_x \|y(x) - a\|^2$

- Všimněme si, že má tvar $C = \frac{1}{n} \sum_{i=1}^n C_i$

- Musíme spočítat gradient přes všechna

tréninková data $\overrightarrow{\nabla C} = \frac{1}{n} \sum_{i=1}^n \overrightarrow{\nabla C_i}$

Učení NN - stochastic gradient descent

- Vylepšení: stochastic gradient descent
- Použijeme aproximaci pomocí *mini-batch*, náhodný výběr **m** tréninkových dat

Učení NN - stochastic gradient descent

- Vylepšení: stochastic gradient descent
- Použijeme aproximaci pomocí *mini-batch*, náhodný výběr **m** tréninkových dat

$$\overrightarrow{\nabla C} = \frac{1}{n} \sum_{i=1}^n \overrightarrow{\nabla C_i} \approx \frac{1}{m} \sum_{j=1}^m \overrightarrow{\nabla C_{i_j}}, \quad i_j \text{ je náhodný index dat}$$

Učení NN - gradient descent

- Pravidlo pro update vah a biasu: $\vec{w} = (w_1, \dots, w_p)^T$,
 $\vec{b} = (b_1, \dots, b_q)^T$, $C = C(\vec{w}, \vec{b})$, $\nabla C_{i_j} = \left(\frac{\partial C_{i_j}}{\partial w_1}, \dots, \frac{\partial C_{i_j}}{\partial p} \right)$ a $\nabla C_{i_j}^{(k)}$ je k -tá složka gradientu

Učení NN - gradient descent

- Pravidlo pro update vah a biasu: $\vec{w} = (w_1, \dots, w_p)^T$,
 $\vec{b} = (b_1, \dots, b_q)^T$, $C = C(\vec{w}, \vec{b})$, $\nabla C_{i_j} = \left(\frac{\partial C_{i_j}}{\partial w_1}, \dots, \frac{\partial C_{i_j}}{\partial p} \right)$ a $\nabla C_{i_j}^{(k)}$ je k -tá složka gradientu

$$w_k \rightarrow \tilde{w}_k = w_k - \frac{\xi}{m} \nabla C_{i_j}^{(k)} = w_k - \frac{\xi}{m} \sum_{j=1}^m \frac{\partial C_{i_j}}{\partial w_k}$$

$$b_l \rightarrow \tilde{b}_l = b_l - \frac{\xi}{m} \nabla C_{i_j}^{(l)} = b_l - \frac{\xi}{m} \sum_{j=1}^m \frac{\partial C_{i_j}}{\partial b_l},$$

Cvičení 4

- Chceme udělat krok Δv , přičemž $\|\Delta v\| = \epsilon$, $\epsilon > 0$, tak, abychom minimalizovali $\Delta C \approx \nabla C \cdot \Delta v$.

Dokažte, že $\Delta v := -\xi \nabla C$, $\xi = \frac{\epsilon}{\|\nabla C\|}$

Cvičení 4

- Chceme udělat krok Δv , přičemž $\|\Delta v\| = \epsilon$, $\epsilon > 0$, tak, abychom minimalizovali $\Delta C \approx \nabla C \cdot \Delta v$.
Dokažte, že $\Delta v := -\xi \nabla C$, $\xi = \frac{\epsilon}{\|\nabla C\|}$
- Jinými slovy dokažte, že “pohyb” ve směru gradientu je optimální krok (tj. vede k největšímu poklesu účelové funkce). Pozor, jen v lokální lineární aproximaci

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$-\|u\|\|v\| \leq |\langle u, v \rangle| \leq \|u\|\|v\|,$$

$$|\langle u, v \rangle| = \|u\|\|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R}$$

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$\begin{aligned} -\|u\|\|v\| &\leq |\langle u, v \rangle| \leq \|u\|\|v\|, \\ |\langle u, v \rangle| &= \|u\|\|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R} \end{aligned}$$

Dosadíme aproximaci účelové funkce do CS nerovnosti:

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$\begin{aligned} -\|u\|\|v\| &\leq |\langle u, v \rangle| \leq \|u\|\|v\|, \\ |\langle u, v \rangle| &= \|u\|\|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R} \end{aligned}$$

Dosadíme aproximaci účelové funkce do CS nerovnosti:

$$-\|\nabla C\| \cdot \|\Delta v\| = -\|\nabla C\| \cdot \epsilon \leq |\langle \nabla C, \Delta v \rangle| = |\nabla C \cdot \Delta v| \leq \|\nabla C\| \cdot \|\Delta v\| = \|\nabla C\| \cdot \epsilon$$

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$\begin{aligned} -\|u\|\|v\| &\leq |\langle u, v \rangle| \leq \|u\|\|v\|, \\ |\langle u, v \rangle| &= \|u\|\|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R} \end{aligned}$$

Dosadíme aproximaci účelové funkce do CS nerovnosti:

$$-\|\nabla C\| \cdot \|\Delta v\| = -\|\nabla C\| \cdot \epsilon \leq |\langle \nabla C, \Delta v \rangle| = |\nabla C \cdot \Delta v| \leq \|\nabla C\| \cdot \|\Delta v\| = \|\nabla C\| \cdot \epsilon$$

Chceme rovnost, tedy musí platit $\Delta v = \alpha \nabla C, \alpha \in \mathbb{R}$

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$\begin{aligned} -\|u\| \|v\| &\leq |\langle u, v \rangle| \leq \|u\| \|v\|, \\ |\langle u, v \rangle| &= \|u\| \|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R} \end{aligned}$$

Dosadíme aproximaci účelové funkce do CS nerovnosti:

$$-\|\nabla C\| \cdot \|\Delta v\| = -\|\nabla C\| \cdot \epsilon \leq |\langle \nabla C, \Delta v \rangle| = |\nabla C \cdot \Delta v| \leq \|\nabla C\| \cdot \|\Delta v\| = \|\nabla C\| \cdot \epsilon$$

Chceme rovnost, tedy musí platit $\Delta v = \alpha \nabla C, \alpha \in \mathbb{R}$

$$\|\nabla C\| \cdot \|\Delta v\| = \|\nabla C\| \cdot \|\alpha \cdot \nabla C\| = |\alpha| \cdot \|\nabla C\|^2 \implies \|\nabla C\| \cdot \epsilon = |\alpha| \cdot \|\nabla C\|^2$$

Cvičení 4

$$\|\Delta v\| = \epsilon \quad \epsilon > 0 \quad \Delta C \approx \nabla C \cdot \Delta v.$$

Nápověda: Cauchy-Schwarzova nerovnost

$$\begin{aligned} -\|u\| \|v\| &\leq |\langle u, v \rangle| \leq \|u\| \|v\|, \\ |\langle u, v \rangle| &= \|u\| \|v\| \iff u = \alpha \cdot v, \alpha \in \mathbb{R} \end{aligned}$$

Dosadíme aproximaci účelové funkce do CS nerovnosti:

$$-\|\nabla C\| \cdot \|\Delta v\| = -\|\nabla C\| \cdot \epsilon \leq |\langle \nabla C, \Delta v \rangle| = |\nabla C \cdot \Delta v| \leq \|\nabla C\| \cdot \|\Delta v\| = \|\nabla C\| \cdot \epsilon$$

Chceme rovnost, tedy musí platit $\Delta v = \alpha \nabla C, \alpha \in \mathbb{R}$

$$\begin{aligned} \|\nabla C\| \cdot \|\Delta v\| &= \|\nabla C\| \cdot \|\alpha \cdot \nabla C\| = |\alpha| \cdot \|\nabla C\|^2 \implies \|\nabla C\| \cdot \epsilon = |\alpha| \cdot \|\nabla C\|^2 \\ \epsilon &= |\alpha| \cdot \|\nabla C\| \iff \pm \alpha = \frac{\epsilon}{\|\nabla C\|} \implies \Delta v = \pm \frac{\epsilon}{\|\nabla C\|} \cdot \nabla C \end{aligned}$$

Cvičení 5


- Jak to bude v případě funkce jedné proměnné?

Cvičení 5

- Jak to bude v případě funkce jedné proměnné?

$$\nabla C(x) = C'(x) \text{ a zároveň } \Delta v(x) = -\frac{\epsilon}{\|\nabla C(x)\|} \nabla C(x) = -\frac{\epsilon \cdot C'(x)}{\|C'(x)\|}$$

pokud $C'(x) = 0$, jsme v lokálním minimu, pokud $C'(x) > 0$, $\Delta v = -\epsilon$ a v opačném případě $\Delta v = \epsilon$



Cvičení 6

- Jaké výhody a nevýhody má online learning (batch velikosti 1)?

Cvičení 6

- Jaké výhody a nevýhody má online learning (batch velikosti 1)?
 - a. Výhody: učení je rychlé

Cvičení 6

- Jaké výhody a nevýhody má online learning (batch velikosti 1)?
 - a. Výhody: učení je rychlé
 - b. Nevýhody: nepřesnost aproximace gradientu, i extrémní hodnoty v datech mají vliv na úpravu parametrů sítě

**Jenže jak spočítáme gradient
přes všechny váhy a biasy?**